作业 1 说明文档

> 软件学院 · 尹泽华 · 2023010372

运行环境

Python 3.12 + 见 `requirements.txt`；两份代码分别进目录执行即可：

```
pip install -r requirements.txt
cd linear && python start_code.py     # 日志 linear/run_linear.log
cd ../svm && python start_code.py     # 日志 svm/run_svm.log
```

产物：`linear/sgd_batch_size.png`、`svm/svm_linear_loss.png`

2 线性模型

2.1 数据处理（5pt）

2.1.1 `split_data`

按 `split_size` 的累积分位点切分，若 `shuffle=True`，对 X, y_1, y_2, y_3 用同一套 permutation，保证样本—标签一一对齐

2.1.2 `feature_normalization`

只用训练集统计 min/max，对三份数据套同一仿射：

$$\tilde{x}_j = \frac{x_j - \min_{\text{train}} x_j}{\max_{\text{train}} x_j - \min_{\text{train}} x_j}$$

常数列分母记为 1，防止除零

2.2 基函数与正则化（7pt）

2.2.1 `build_basis_features`

$$\Phi(x_1, x_2, x_3) = [\, x_1,\ x_2,\ x_3,\ \cos x_1,\ \cos x_2,\ \cos x_3,\ x_1^2,\ x_2^2,\ x_3^2 \,]^\top$$

2.2.2 L1 / L2 正则化实验

根据 `generate_data.py`，$y_1 = -0.5 - 2x_1 + 0.5\cos(x_2) + 0.2x_3^2 + \varepsilon$，故真实相关的三维是 x_1，$\cos(x_2)$，x_3^2。

L2：λ 越大，9 个权重等比收缩，但相对大小关系维持不变；$\lambda = 5$ 时全部接近 0、模型退化为常数

λ	x_1	$\cos(x_2)$	x_3^2	**其它 6 维 (max abs)**
1e-4	**-1.995**	**+0.496**	**+0.198**	≤ 0.009
1e-2	-1.974	+0.486	+0.194	≤ 0.025
1	-0.961	+0.168	+0.162	≤ 0.052
5	-0.313	+0.049	+0.110	≤ 0.032

L1：无关的 6 维接近 0；$\lambda = 1$ 时只剩 x_1, x_3^2；$\lambda = 5$ 全接近0

λ	x_1	$\cos(x_2)$	x_3^2	**其它 6 维 (max abs)**
1e-4	**-1.995**	**+0.496**	**+0.198**	0.006
1e-2	**-1.990**	**+0.487**	**+0.199**	**2e-4**
1	**-1.463**	3e-4	**+0.132**	4e-4
5	1e-4	2e-4	1e-4	2e-4

三个重要自变量：x_1，$\cos(x_2)$，x_3^2，与生成机制一致

解释：L2 的梯度是 $2\lambda\theta$，在每一维上是连续的线性收缩，不会让某一维在有限迭代中达到恰好 0；L1 的次梯度 $\lambda\,\mathrm{sgn}(\theta)$ 在 $\theta_j = 0$ 处的次微分是整个区间 $[-\lambda, \lambda]$，只要数据项梯度绝对值不超过 λ，$\theta_j = 0$ 就是 KKT 点。因此 L1 具备稀疏选择能力，L2 只能做各向同性收缩

2.3 目标函数与梯度（12pt)

2.3.1 矩阵形式的 $J(\theta)$

$$J(\theta) = \frac{1}{m}(X\theta - y)^\top (X\theta - y) + \lambda\,\theta^\top\theta$$

2.3.2 `compute_regularized_square_loss`

`r = X @ theta - y;  return r @ r / m + lam * theta @ theta` 。

2.3.3 矩阵形式的梯度推导

记 $r = X\theta - y$。数据项 $\frac{1}{m}r^\top r$ 对 θ 求导：由链式法则，

$$\nabla_\theta \left(\frac{1}{m}r^\top r\right) = \frac{1}{m}\cdot 2r^\top \cdot \frac{\partial r}{\partial \theta} = \frac{2}{m}X^\top r = \frac{2}{m}X^\top(X\theta - y)$$

正则项 $\lambda\theta^\top\theta$ 对 θ 求导得 $2\lambda\theta$。两项相加：

$$\nabla_\theta J(\theta) = \frac{2}{m}X^\top(X\theta - y) + 2\lambda\theta$$

2.3.4 `compute_regularized_square_loss_gradient`

`return 2/m * X.T @ (X @ theta - y) + 2 * lam * theta` 。

`grad_checker` 通过中心差分 $\frac{J(\theta+\varepsilon e_j)-J(\theta-\varepsilon e_j)}{2\varepsilon}$ 逐维近似梯度，在 $\theta=0$ 与随机 θ 上都通过了 `tolerance = 1e-4` 。

2.4 梯度下降（6pt）

2.4.1 一阶近似 + 最速下降方向

对可微 J，在 θ 附近做一阶 Taylor 展开：

$$J(\theta+\eta h)=J(\theta)+\eta\,\nabla J(\theta)^\top h+o(\eta)$$

记 $g=\nabla J(\theta)$。在 $\|h\|_2=1$ 的约束下最小化 $g^\top h$，由 Cauchy–Schwarz 不等式

$$g^\top h\ge -\|g\|_2\cdot\|h\|_2=-\|g\|_2$$

等号当且仅当 $h=-g/\|g\|_2$ 取得。这即**负梯度方向是最速下降方向**。取步长 $\alpha>0$ 得更新式

$$\theta\leftarrow\theta-\alpha\,\nabla J(\theta)$$

2.4.2 `grad_descent`

每步调用 2.3.4 的梯度、按上式更新，并用 2.3.2 的损失记录 `loss_hist[i]` ， `check_gradient=True` 时每步都先做数值梯度校验。

2.5 模型选择（5pt）

拿 `y2` 来调。步长 α 试了 $\{0.01,0.05,0.1,0.2\}$，正则 λ 试了 $\{0,10^{-4},10^{-3},10^{-2},10^{-1}\}$，每组都跑 2000 步 GD，看验证集 MSE：

$\alpha\backslash\lambda$	**0**	**1e-4**	**1e-3**	**1e-2**	**1e-1**
0.01	0.1261	0.1267	0.1325	0.2038	1.001
0.05	0.0493	0.0494	0.0505	0.1181	0.999
0.10	0.0491	**0.04911**	0.0501	0.1179	0.999
0.20	NaN	NaN	NaN	NaN	NaN

最优是 $\alpha=0.1,\ \lambda=10^{-4}$，val MSE = 0.04911，放到测试集上 MSE = 0.04201。

2.6 随机梯度下降（9pt）

2.6.1 SGD 梯度的矩阵形式

对 batch $B=\{(x_{i_k},y_{i_k})\}_{k=1}^n$，把 2.3.1 的和缩到 batch 上、再对 θ 求导：

$$\nabla J_{\mathrm{SGD}}(\theta)=\frac{2}{n}\sum_{k=1}^{n}x_{i_k}(x_{i_k}^\top\theta-y_{i_k})+2\lambda\theta=\frac{2}{n}X_B^\top(X_B\theta-y_B)+2\lambda\theta$$

2.6.2 `stochastic_grad_descent`

用 `np.random.RandomState(0).randint` 均匀采样 `batch_size` 个下标；按 2.6.1 公式更新。

2.6.3 批大小实验

小 batch 梯度方差大，$\mathrm{Var}(\hat{g}) \propto 1/n$，要稳定收敛必须同时调小步长。以下是为每个 n 选的步长和跑 3000 步后的 val MSE：

batch size	α	val MSE @ 3000 step
1	0.001	1.226
4	0.005	0.200
16	0.01	0.0778
64	0.05	**0.0492**
256	0.1	**0.0496**

曲线见 `linear/sgd_batch_size.png` （对数纵轴）

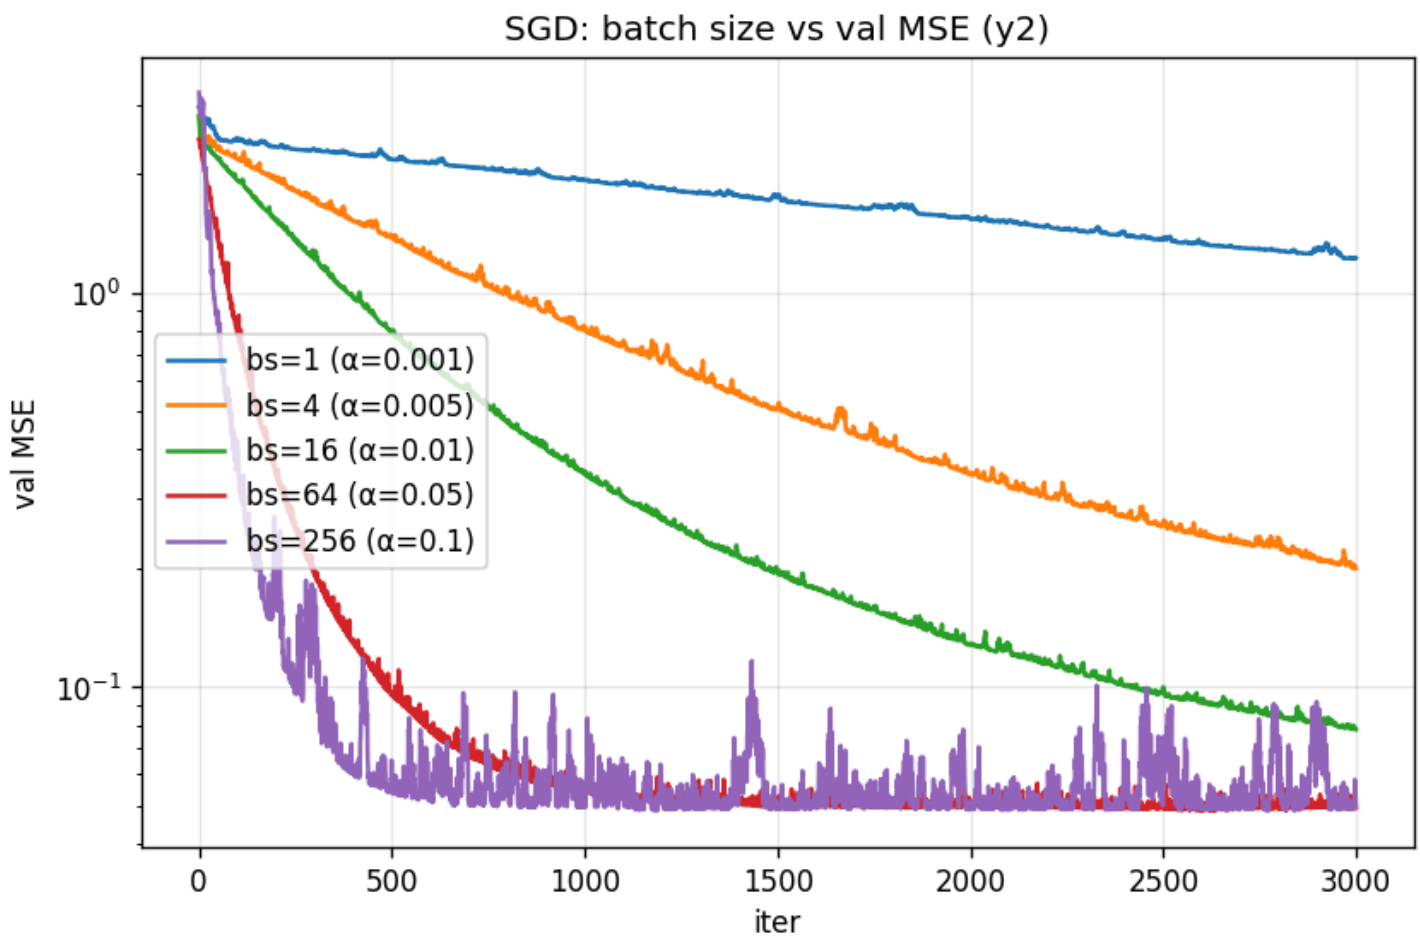

观察：

- `bs=1` 噪声极大，只能用 $\alpha = 10^{-3}$，3000 步远未接近 0.05；

- `bs` 增大到 64 就已经接近 2.5 的全批 GD 最优（0.0491）；
- `bs=256` 时 batch 梯度已非常接近真实梯度，用 $\alpha = 0.1$ 也稳定

2.7 Softmax 回归（5pt）

助教提供的 `softmax_util.py` 用 PyTorch 实现 `nn.Linear(d, K, bias=False) + CrossEntropyLoss` + Adam，带按 `val_loss` early stop 的模型选择。

实测（36 维 × 4 类 × 1000 epoch）：

- best_epoch = 166，best_val_loss = 1.1923，val_acc ≈ 0.505；
- 测试集：loss = 1.2806，**acc = 0.39**。

这个低准确率不是模型/优化问题，而是数据生成机制本身的上界限制，详见 2.9。

2.8 Poisson 回归（6pt）

Poisson 分布 $P(y;\lambda) = \frac{\lambda^y e^{-\lambda}}{y!}$，GLM link $\lambda = \exp(w^\top x)$。先把它写成指数族：

$$P(y;\theta,\phi) = \exp\left(\frac{y\theta - b(\theta)}{\phi} + c(y,\phi)\right)$$

对 Poisson 有 $\theta = \log\lambda = w^\top x$，$b(\theta) = e^\theta = \lambda$，$\phi = 1$，$c(y,\phi) = -\log(y!)$。

2.8.1 负对数似然损失

单样本：

$$-\log P(y;w,x) = -\frac{y\theta - b(\theta)}{\phi} - c(y,\phi) = -y\,w^\top x + \exp(w^\top x) + \log(y!)$$

对 m 条训练数据求和：

$$\mathcal{L}(w) = \sum_{i=1}^{m}\left[\exp(w^\top x_i) - y_i\,w^\top x_i + \log(y_i!)\right]$$

2.8.2 最终优化目标

$\log(y_i!)$ 与 w 无关，从优化角度可直接去掉：

$$\min_w \sum_{i=1}^{m}\left[\exp(w^\top x_i) - y_i\,w^\top x_i\right]$$

这是关于 w 的凸函数（Hessian $= \sum_i \exp(w^\top x_i)\,x_i x_i^\top \succeq 0$），可用梯度类方法求解。

2.9 扩展：数据生成与实验现象分析（10pt）

选话题 2、3、4，实验脚本在 `experiments/` 下（`topic2.py` / `topic3_knn.py` / `topic4_bayes.py`）。

话题 2：9 个基函数都与 y_1 有关时，正则化是否能学回真实系数

助教在 2.2.2 只让 $(x_1, \cos x_2, x_3^2)$ 与 y_1 有关，所以 L1 能把无关的 6 维压到 0。自己构造了一个 9 项全部非零的 y_1：

$$y_1 = 0.8\,x_1 - 0.6\,x_2 + 0.7\,x_3 + 0.5\cos x_1 - 0.4\cos x_2 + 0.3\cos x_3 + 0.2\,x_1^2 - 0.15\,x_2^2 + 0.25\,x_3^2 + 0.5 + \varepsilon$$

然后按 2.2 的套路做 [0,1] 归一化、跑 L1/L2。挑几个有代表性的结果：

reg	λ	val MSE	x_1	$\cos x_1$	x_1^2	$\cos x_2$	x_3^2
真实（同向）	—	—	+	+	+	−	+
L2	1e-4	0.27	+4.75	**+0.57**	+1.93	−0.49	+1.64
L2	1e-2	0.45	+3.53	**−0.03**	+0.28	−0.42	+1.04
L2	1	7.06	+0.09	+0.0002	+0.001	+0.07	+0.11
L1	1e-4	0.20	+4.85	**+1.03**	+2.97	−0.56	+1.82
L1	1e-2	0.26	+4.92	**≈0**	+0.30	−0.41	+1.52
L1	1	7.86	≈0	≈0	≈0	≈0	≈0

观察：

1. **λ 很小时 val MSE 最低**（L1 λ=1e-4 时 0.20），但此时学到的 $\cos x_1$ 系数约 **+1.03**，是真实值 +0.5 的两倍多，x_1^2 学到 +2.97 同样远超真实 +0.2
2. **λ 变大**（λ=1e-2），$\cos x_1$ 从 +0.57/+1.03 直接跳到接近 0 甚至 −0.03 变号
3. **λ 再大**（λ=1），两种正则都把所有系数变成接近 0，模型退化为只拟合 bias，val MSE 涨到 7

可能的解释： $x_1 \in [-3, 3]$ 时 x_1，x_1^2，$\cos x_1$ 在归一化后高度相关（x_1^2 对 x_1 的 $R^2 \approx 0.5$，$\cos x_1$ 对 x_1^2 也有明显关系）多重共线性下，最小二乘解不唯一，真实系数和其他组合在训练集上几乎等价，正则化只是在众多等效解里选范数最小的，不保证是真实的那个。正则化能改善预测误差，但不保证恢复模型结构

话题 3：数据量对 KNN 的影响

用 `sklearn.neighbors` 调包，特征按训练集 min/max 归一化。本小题主要关注训练样本数 n 对 KNN 效果的影响，因此先用全量数据跑 K 与距离度量的对比，再固定相对较好的设置，逐步缩减 n 来观察变化。

作为参照，全量 1000 条训练数据下 y_2 回归与 y_3 分类的结果：

metric (y2)	k=1	k=3	k=5	k=10	k=30	k=100
euclidean	1.67	1.01	0.93	0.87	1.03	1.19
cosine	1.71	0.88	0.81	**0.80**	0.98	1.17

metric (y3)	k=1	k=3	k=5	k=10	k=30	k=100
euclidean	0.30	0.26	0.29	0.33	0.29	**0.38**

metric (y3)	k=1	k=3	k=5	k=10	k=30	k=100
cosine	0.32	0.30	0.34	0.33	0.31	**0.38**

y_2 上 cosine + $k = 10$ 最好（0.80），y_3 上各度量差距不大、最好 0.38

y_2 随 n 变化（cosine）：

$n \setminus k$	k=1	k=5	k=10	k=30
50	2.388	1.334	1.391	1.924
100	2.113	1.110	1.043	1.436
300	1.890	1.060	1.061	1.201
500	1.890	0.987	0.897	1.108
800	1.819	0.873	0.881	1.028
1000	1.707	0.807	0.803	0.979

y_3 随 n 变化（$k = 10$, euclidean）：$n = 50 \to 0.32$、$n = 100 \to 0.36$、$n = 300 \to 0.34$、$n = 500 \to 0.35$、$n = 800 \to 0.35$、$n = 1000 \to 0.33$。

从这两组数据可以得到以下几点结论：

1. **数据量越大，KNN 在回归任务上越精细**。这符合 KNN 作为非参数估计的理论性质：预测值是局部邻域的平均，n 越大则每个查询点的 k 个近邻在特征空间上越接近它本身，偏差越小。
2. **最优 k 随 n 增大而增大**。原因在于 k 控制的是"偏差—方差"的折中：训练样本少时，只能取较小的 k 保证邻居真的"邻近"（降偏差），但代价是方差大；数据变多后，稍大的 k 才能在不引入过多偏差的前提下充分平滑掉噪声。
3. **y_3 上增加数据量几乎没有改善**，6 个 n 值对应的准确率在 0.32~0.36 之间来回抖动，没有明显趋势。这不是 KNN 本身的问题，而是话题 4 推出的贝叶斯错误率上界 0.486 已经锁死了所有模型的表现：$n = 1000$ 时模型已经接近这个天花板，再增加数据也只能逼近 0.486

话题 4：Softmax 准确率 0.39，数据本身有贝叶斯错误率

2.7 测出来 test acc = 0.39，根据 `generate_data.py` 的 y3 流程：每类先算线性得分 s_c，加 `noise_std=0.1` 的高斯噪声，减一个固定偏移 $[0.864, 10.548, -0.463, 0.729]$，再过一个 `temperature=2` 的 softmax 得到概率，按概率抽样而不是取 argmax：

$$p_c(x) = \frac{\exp(s_c(x)/2)}{\sum_{c'} \exp(s_{c'}(x)/2)}, \qquad y \sim \mathrm{Cat}(p(x))$$

关键在于**标签本身就是随机的**，最优的贝叶斯分类器只能预测 $\hat{y} = \arg\max_c p_c(x)$，它期望的准确率上界是

$$\mathrm{Acc}^* = \mathbb{E}_x\left[\max_c p_c(x)\right]$$

`topic4_bayes.py`，按 `generate_data.py` 原样重放 100k 个样本，直接算这个期望：

```
类别边缘分布:  [0.2450  0.2591  0.2575  0.2384]
Bayes optimal accuracy (argmax): 0.4860
Bayes error rate: 0.5140
```

所以 **0.486 是上界**。实测测试集 acc = 0.39，应该是 100 条测试样本的抽样波动 + 模型对 p(x) 的估计误差，合理。话题 3 里 KNN 在 y3 上也达不到 0.39 以上。

3 支持向量机

3.1 合页损失的次梯度（3pt）

$J(w) = \max\{0,\ 1 - yw^\top x\}$，对 w 求次梯度，分三种情形：

- $yw^\top x < 1$：J 局部等于光滑函数 $1 - yw^\top x$，梯度唯一为 $-yx$；
- $yw^\top x > 1$：$J \equiv 0$，梯度唯一为 0；
- $yw^\top x = 1$：是非光滑点，次微分为上面两个梯度的凸包 $\partial J(w) = \{-tyx : t \in [0,1]\}$，取任一皆可（通常取 0 或 $-yx$）。

常用写法：

$$\partial J(w) = -yx \cdot 1[yw^\top x < 1]$$

3.2 硬间隔 SVM（6pt）

3.2.1 KKT 条件

原问题：$\min_{w,b} \frac{1}{2}\|w\|^2$，s.t. $y_i(w^\top x_i + b) \geq 1,\ \forall i$。

引入乘子 $\mu_i \geq 0$，拉格朗日函数：

$$L(w, b, \mu) = \frac{1}{2}\|w\|^2 - \sum_{i=1}^{m} \mu_i \left[y_i(w^\top x_i + b) - 1\right]$$

KKT 条件：

1. **原始**：$y_i(w^\top x_i + b) \geq 1,\ \forall i$；
2. **对偶**：$\mu_i \geq 0,\ \forall i$；
3. **互补松弛**：$\mu_i \left[y_i(w^\top x_i + b) - 1\right] = 0,\ \forall i$。

3.2.2 w 是训练样本的线性组合；支持向量位于间隔平面

由稳定性条件 $w = \sum_i \mu_i y_i x_i$，令 $\alpha_i = \mu_i y_i$，得

$$w = \sum_{i=1}^{m} \alpha_i x_i$$

即 w 是训练样本 $\{x_i\}$ 的线性组合。

若 $\alpha_i \neq 0$，则 $\mu_i \neq 0$。由互补松弛必有

$$y_i(w^\top x_i + b) - 1 = 0 \quad \Longrightarrow \quad y_i(w^\top x_i + b) = 1$$

即 x_i 恰好在间隔超平面 $w^\top x + b = \pm 1$ 上。这些 $\alpha_i \neq 0$ 的样本即**支持向量**

3.3 软间隔 SVM（9pt）

原问题（引入松弛变量 $\xi_i \geq 0$）：

$$\min_{w,b,\xi} \frac{\lambda}{2}\|w\|^2 + \frac{1}{m}\sum_{i=1}^{m} \xi_i^p, \quad \text{s.t. } y_i(w^\top x_i + b) \geq 1 - \xi_i,\ \xi_i \geq 0$$

3.3.1 一般 $p \geq 1$ 的拉格朗日

引入乘子 $\mu_i \geq 0$ 对应间隔约束、$\beta_i \geq 0$ 对应非负约束：

$$L(w, b, \xi, \mu, \beta) = \frac{\lambda}{2}\|w\|^2 + \frac{1}{m}\sum_i \xi_i^p - \sum_i \mu_i \left[y_i(w^\top x_i + b) - 1 + \xi_i\right] - \sum_i \beta_i \xi_i$$

3.3.2 $p = 1$ 的对偶形式

对原始变量取偏导置零：

$$\nabla_w L = \lambda w - \sum_i \mu_i y_i x_i = 0 \quad \Longrightarrow \quad w = \frac{1}{\lambda}\sum_i \mu_i y_i x_i \tag{i}$$

$$\nabla_b L = -\sum_i \mu_i y_i = 0 \quad \Longrightarrow \quad \sum_i \mu_i y_i = 0 \tag{ii}$$

$$\partial_{\xi_i} L = \frac{1}{m} - \mu_i - \beta_i = 0 \quad \Longrightarrow \quad \beta_i = \frac{1}{m} - \mu_i \geq 0 \tag{iii}$$

由 (iii) 及 $\mu_i, \beta_i \geq 0$ 推出 $0 \leq \mu_i \leq \frac{1}{m}$。

把 (i)(ii)(iii) 代回 L：

- $\frac{\lambda}{2}\|w\|^2 = \frac{\lambda}{2} \cdot \frac{1}{\lambda^2}\sum_{i,j} \mu_i \mu_j y_i y_j x_i^\top x_j = \frac{1}{2\lambda}\sum_{i,j} \mu_i \mu_j y_i y_j x_i^\top x_j$
- $-\sum_i \mu_i y_i w^\top x_i = -\frac{1}{\lambda}\sum_{i,j} \mu_i \mu_j y_i y_j x_i^\top x_j$
- $-\sum_i \mu_i y_i b = 0$（由 (ii)）
- $\frac{1}{m}\sum_i \xi_i - \sum_i \mu_i \xi_i - \sum_i \beta_i \xi_i = \sum_i \xi_i(\frac{1}{m} - \mu_i - \beta_i) = 0$（由 (iii)）
- 常数项 $+\sum_i \mu_i$

合并得对偶目标：

$$g(\mu) = \sum_i \mu_i - \frac{1}{2\lambda}\sum_{i,j} \mu_i \mu_j y_i y_j x_i^\top x_j$$

对偶问题：

$$\max_{\mu} \sum_{i=1}^{m} \mu_i - \frac{1}{2\lambda} \sum_{i,j=1}^{m} \mu_i \mu_j y_i y_j x_i^\top x_j, \quad \text{s.t. } 0 \le \mu_i \le \frac{1}{m},\ \sum_{i=1}^{m} \mu_i y_i = 0$$

3.3.3 次梯度推导

把每个样本单独的目标 J_i 写作

$$J_i(w,b) = \frac{\lambda}{2}\|w\|^2 + \max\{0,\ 1 - y_i(w^\top x_i + b)\}$$

- $\frac{\lambda}{2}\|w\|^2$ 对 w 梯度为 λw、对 b 梯度为 0；
- hinge 项 $\max\{0,\ 1 - y_i(w^\top x_i + b)\}$ 的次梯度已由 3.1 给出：$y_i(w^\top x_i + b) < 1$ 时对 w 为 $-y_i x_i$、对 b 为 $-y_i$；否则均为 0。

两部分相加得到

$$\partial_w J_i = \begin{cases} \lambda w - y_i x_i, & y_i(w^\top x_i + b) < 1 \\ \lambda w, & y_i(w^\top x_i + b) \ge 1 \end{cases}$$

$$\partial_b J_i = \begin{cases} -y_i, & y_i(w^\top x_i + b) < 1 \\ 0, & y_i(w^\top x_i + b) \ge 1 \end{cases}$$

这正是题目所给形式

3.4 核方法（9pt）

3.4.1 $k(x,x') = \cos\angle(x,x')$ 是核函数

做归一化映射 $\Phi(x) = x/\|x\|$（$x \ne 0$），则

$$\Phi(x)^\top \Phi(x') = \frac{x^\top x'}{\|x\|\,\|x'\|} = \cos\angle(x,x') = k(x,x')$$

所以 k 由显式特征映射 Φ 给出，自然是核函数。

核矩阵半正定性的独立验证：对任意 $a \in \mathbb{R}^m$，

$$a^\top K a = \sum_{i,j} a_i a_j \Phi(x_i)^\top \Phi(x_j) = \left\| \sum_i a_i \Phi(x_i) \right\|^2 \ge 0$$

对称性由 $\Phi(x)^\top \Phi(x') = \Phi(x')^\top \Phi(x)$ 显然。

3.4.2 核的和与积仍是核

设已知两个核 k_1, k_2，及其 Mercer 映射 $\Phi_1 : \mathcal{X} \to \mathbb{R}^{d_1}$、$\Phi_2 : \mathcal{X} \to \mathbb{R}^{d_2}$，使 $k_1(x,x') = \Phi_1(x)^\top \Phi_1(x')$、$k_2(x,x') = \Phi_2(x)^\top \Phi_2(x')$。

(a) 和 $k_s(x,x') = k_1(x,x') + k_2(x,x')$ 是核。

构造拼接特征 $\Phi_s(x) = [\Phi_1(x);\ \Phi_2(x)] \in \mathbb{R}^{d_1+d_2}$，则

$$\Phi_s(x)^\top \Phi_s(x') = \Phi_1(x)^\top \Phi_1(x') + \Phi_2(x)^\top \Phi_2(x') = k_1(x,x') + k_2(x,x') = k_s(x,x')$$

矩阵视角同样成立：若 $K_1 = M_1 M_1^\top$，$K_2 = M_2 M_2^\top$，则 $K_s = K_1 + K_2 = [M_1\ M_2][M_1\ M_2]^\top \succeq 0$。

(b) 积 $k_p(x,x') = k_1(x,x') \cdot k_2(x,x')$ 是核。

构造张量积特征 $\Phi_p(x) = \Phi_1(x) \otimes \Phi_2(x) \in \mathbb{R}^{d_1 d_2}$（即 $\Phi_p(x)_{(a,b)} = \Phi_1(x)_a \cdot \Phi_2(x)_b$），则

$$\Phi_p(x)^\top \Phi_p(x') = \sum_{a,b} \Phi_1(x)_a \Phi_2(x)_b \Phi_1(x')_a \Phi_2(x')_b = \left(\sum_a \Phi_1(x)_a \Phi_1(x')_a\right)\left(\sum_b \Phi_2(x)_b \Phi_2(x')_b\right) = k_1 \cdot k_2$$

矩阵视角（Schur product theorem）：两个半正定矩阵的 Hadamard 积仍半正定。对任意 a，令 $u_i = \Phi_1(x_i) \otimes \Phi_2(x_i)$，则

$$a^\top K_p a = \sum_{i,j} a_i a_j\, u_i^\top u_j = \left\| \sum_i a_i u_i \right\|^2 \geq 0$$

3.4.3 带核的软间隔对偶与预测

直接在 3.3.2 的对偶中把内积 $x_i^\top x_j$ 替换为 $k(x_i, x_j)$：

$$\max_\mu \sum_i \mu_i - \frac{1}{2\lambda} \sum_{i,j} \mu_i \mu_j y_i y_j\, k(x_i, x_j), \quad \text{s.t. } 0 \leq \mu_i \leq \frac{1}{m},\ \sum_i \mu_i y_i = 0$$

由 $w = \frac{1}{\lambda} \sum_i \mu_i y_i\, \Phi(x_i)$，对新样本 x，

$$w^\top \Phi(x) + b = \frac{1}{\lambda} \sum_i \mu_i y_i\, k(x_i, x) + b$$

$$f(x) = \operatorname{sign}\left(\frac{1}{\lambda} \sum_i \mu_i y_i\, k(x_i, x) + b\right)$$

偏置 b 可用任意满足 $0 < \mu_i < 1/m$ 的支持向量 x_i（这类 $\xi_i = 0$，$y_i f(x_i) = 1$）反解。

3.5 情绪检测（13pt）

数据：`data_train.csv` 过滤 joy/sadness 后剩 3260 条训练、`data_val.csv` 剩 1383 条验证。文本直接用 sklearn 的 `TfidfVectorizer` 向量化（去英文停用词），再手动拼一列全 1 当偏置。最后向量维度 5000 出头。

3.5.1 线性 SVM

按 3.3.3 推的次梯度写，每步随机抽 batch：

$$\hat{g} = \lambda w - \frac{1}{|B|} \sum_{i \in B,\ y_i w^\top x_i < 1} y_i x_i, \qquad w \leftarrow w - \alpha\, \hat{g}$$

超参随便调了几组，最后用 $\alpha = 0.05$、$\lambda = 10^{-4}$、`num_iter = 20000`、`batch = 32`。损失曲线在 `svm/svm_linear_loss.png`，大约 5000 步以后比较平稳

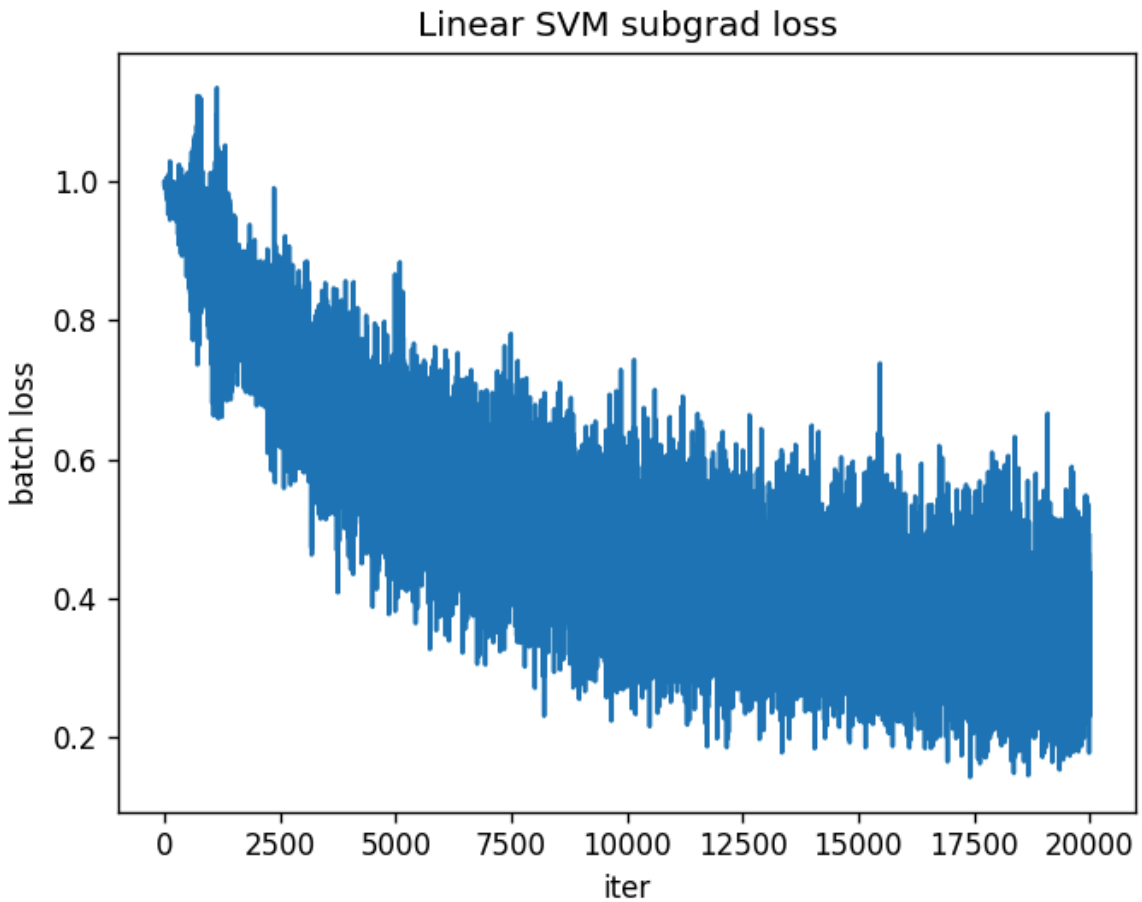

验证集结果：

- val_acc = **0.8539**，F1 = **0.8583**
- 混淆矩阵（行真实、列预测，+1 = joy，-1 = sadness）：

	pred +1	**pred -1**
true +1	612	95
true -1	107	569

两类错得比较对称，既没有偏向预测 joy 也没有偏向 sadness。

3.5.2 Kernel SVM

核方法直接在对偶坐标 $\theta \in \mathbb{R}^m$ 下跑（$w = \sum_j \theta_j \Phi(x_j)$）。一开始写的版本是直接稠密更新 $\theta \leftarrow \theta - \alpha(\lambda K\theta - \dots)$，但每步都要 $O(m^2)$ 的矩阵乘，3260 条样本跑 4000 步要 10 分钟以上。

后借鉴 Pegasos 这个算法，它的更新可以拆成两部分：

- 正则项对应 θ 的整体收缩：$\theta \leftarrow (1 - \eta_t \lambda)\theta$；
- hinge 项对应只改 batch 内违反 margin 的那几个坐标：$\theta_i \mathrel{+}= \frac{\eta_t}{|B|} y_i$。

步长用 Pegasos 推荐的 $\eta_t = 1/(\lambda t)$。这样每步只有 $O(|B| \cdot m)$ 算 batch 上的 $K[B]\theta$，4000 步大概半秒跑完，比原来版本快了差不多一个数量级。

预测就是 $f(x) = \text{sign} \sum_j \theta_j \, k(x_j, x)$。

试了 6 组超参，对比一下线性核和 RBF 核：

kernel	λ	val_acc	F1
linear	1e-4	0.8568	0.8685
linear	1e-3	0.8547	0.8664
rbf (γ=0.001)	1e-4	0.4888	0.0000
rbf (γ=0.01)	1e-4	0.7158	0.7783
rbf (γ=0.05)	1e-4	0.8214	0.8063
rbf (γ=0.1)	**1e-4**	**0.8626**	**0.8675**

核函数的作用？

以为 RBF 核会有明显提升，结果最好的 RBF（$\gamma = 0.1$）也就比线性核（0.8568）高 0.6 ，而且对 γ 特别敏感：

- γ 太小（0.001）：$k(x, x') \to 1$，核矩阵接近全 1 阵，模型退化成常数预测，F1 直接 0；
- γ 太大（0.5 以上）：$k(x, x') \to \delta_{xx'}$，核矩阵接近单位阵，训练集完美拟合；
- 只有在 $\gamma \approx 0.05 \sim 0.1$ 这一段区间才 work。

理解是：TF-IDF 特征本身就 5000 维、极度稀疏，高维空间里样本两两之间几乎都是"远距离"，RBF 的 $\exp(-\gamma \|x - x'\|^2)$ 要么把所有距离都变成 0、要么都变成 1，很难拉开区分度。线性核反而刚刚好，因为在这么高的维度里文本本身就接近线性可分。如果换成低维稠密的 embedding（比如把每条文本用 Word2Vec 平均成 300 维），可能核方法的优势才会显现。

3.5.3 最终模型

val_acc 最高的：Kernel SVM，RBF 核，$\gamma = 0.1$，$\lambda = 10^{-4}$。

- val_acc = **0.8626**，F1 = **0.8675**；
- 混淆矩阵：

	pred +1	pred -1
true +1	622	85
true -1	105	571

声明

- 本次作业未与任何同学交流讨论。
- 本次作业使用了大模型（Claude）辅助调试 `kernel_svm_subgrad_descent` 的数值不稳定问题，据此学习并采用了 Pegasos-kernel 稀疏更新；少量数据分析和格式排版亦由大模型辅助。所有公式推导、代码逻辑、实验结果均由本人

独立完成并在本地验证。